+ Try on this page

#### Type something.

01) Visualizing and Understanding


- 01\_Visualize Filters
  - 1. First Laver
  - 2. Last Layer
  - 3. Dimensionality Reduction
  - 4. Maximally Activation Patches

  - 6. Saliency Maps
  - 7. Intermediate features via quided backprop
  - 8. Visualizating CNN features: Grdaient Ascent
  - 9. Fooling Images / Adversarial Examples
  - 10. DeepDream: Amplify existing features
  - 11. Feature inversion
  - 12. Texture Synthesis
  - 13. Gram Matrix
  - 14. Neural Style Transfer

#### 01\_Visualize Filters

#### 1. First Layer

### First Layer: Visualize Filters




AlexNet: 64 x 3 x 11 x 11




ResNet-18: 64 x 3 x 7 x 7



ResNet-101: 64 x 3 x 7 x 7



DenseNet-121: 64 x 3 x 7 x 7



- AlexNet 첫번째 conv결과로 3 x 11 x 11 feature map이 나오게 되며, filter의 가중치와 input 이미지의 내적을 통해 구해진다.
- feature map은 보통 oriented edge나 complementary color(보색, 색상 대비를 이루는 한쌍의 색상) 등을 찾아낸다.
- 첫번째 layer는 이미지와 가장 가까운 곳에 접하기 때문에 이미지의 특성을 잡아내는데 유리하다.

### Visualize the filters/kernels (raw weights)

We can visualize filters at higher layers, but not

#### Weights: DESCRIPTION OF THE PROPERTY OF

**化聚物基础等的现在分词 (约约约即位为阿尔尔斯等的公司的)(自存的现代的民族的) 在以)(如识出印度的安尼的中国来源于人的)(由我以西西河通报的阿田等自由申请)(由创度分数** 四型以前用的保护中型型)(用限过程的单元并将用用用用用的)(物理是的通用的建筑性的 用重加证(创作的现在分词中的重点的对象的)(证明的对象的对象的对象的的对象的形式)(如此重要的的)(如此重要的)(如此是一种的)(如此是一种的)(如此是一种的) 所が利用を表示なる。(ののののでは、10mmのでは、10 我要因為學者自由可能的學者以及自由學者的所有所以以及自由學者的可能

layer 2 weights 20 x 16 x 7 x 7

layer 1 weights

16 x 3 x 7 x 7

国国国际运行规则)

### that interesting

(these are taken from ConvNetJS CIFAR-10 demo)

#### Weights:

)(四級國家聯盟國國通過國際國際無限問題權限)(國際法院的認定政治所必可以過過因過過必必 至國)(伊州南部北京市政治學所屬的北京市政治學所屬的北京市政治學所屬的北京市政治學所屬的 整動學經經濟整備整體性高程準)(這項同應河遊經過程施設信養學學學院提定基)(從奠厚為取 新规模等单位(国际基础证明的)(国际基础证明是基础证明的证明的证明证明的证明证明的证明 建场社员点序的(使短级整理者盖层整整理程度需要因处理的)(を运行点和正定位度和当所 俗称或是是否可以)

layer 3 weights

20 x 20 x 7 x 7


- 16 x 3 x 7 x 7 → 20 x 16 x 7 x 7 laver들을 통과할 수록 점점 깊어져간다.
- 하지만 layer가 깊어질수록 시각화로 통해 우리가 볼 수 없다.

#### 2. Last Laver

### Last Layer: Nearest Neighbors

4096-dim vector





Recall: Nearest neighbors



- NN을 pixel 단위로 적용시켰을 때는 정확도가 낮지만 feature space에서는 무난한 성능을 보여준다.
- 코끼리를 예시로 들면 코끼리가 왼쪽에 있든, 오른쪽에 있든 같은 객체로 인식한다는 것이다.


#### 3. Dimensionality Reduction

Last Layer: Dimensionality Reduction

Visualize the "space" of FC7 feature vectors by reducing dimensionality of vectors from 4096 to 2 dimensions

Simple algorithm: Principle Component Analysis (PCA)


More complex: t-SNE



- 4096 → 2D로 차원을 축소할 때 PCA라는 기법을 많이 사용한다.
- 딥러닝에서는 tisse 라는 non-linearity를 가진 함수를 이용하여 feature를 차원 축소한다.

### Visualizing Activations


conv5 feature map is 128x13x13; visualize as 128 13x13 grayscale images



Yosinski et al, "Understanding Neural Networks Through Deep Visualization", ICML Dt. Workshop 201 Figure consolidit Japon Yosinski, 2014. Reconducted with permission.

- AlexNet의 conv5 activation map에서 사람 얼굴과 비슷한 이미지를 확인할 수 있었다.
- 4. Maximally Activation Patches

# Maximally Activating Patches



Pick a layer and a channel; e.g. conv5 is 128 x 13 x 13, pick channel 17/128

Run many images through the network, record values of chosen channel


Visualize image patches that correspond to maximal activations





Springenberg et al. "Striving for Simplicity: The All Convolutional Net", ICLR Workshop 2015. Figure copyright Jost Tobias Springeriberg, Alexey Dosovitskiy, Thomas Brox, Martin Riedmiller, 2015.

• Maximally Activating Patches라는 방법은 특정 neuron에서 activation이 가장 큰 patch를 시각화 하는 방법이다.



- image patch 와 kernel은 inner product했을 때 하나의 activation 값이 나오게 된다.
- activation 값이 크다는 것은 해당 filter에 대해 높게 반응했다는 것이고, activation값이 높은 부분을 캡쳐해보면 neural network가 중요하게 보는 부분을 확인할 수 있다.


#### 5. Occlusion Experiments





# Occlusion Experiments

Mask part of the image before feeding to CNN, draw heatmap of probability at each mask location










African elephant, Loxodonta africana









Zeiler and Fergus, "Visualizing and Understanding Convolutional Networks" FCCV 2014


occlusion: 어떤 물체 앞에 장애물이 있어서 가려지는 현상

- 이미지를 가리는 부분을 옮겨가면서 어떤 변화가 있는지 측정을 하여 heatmap으로 나타내었다.
- 특정 구간을 가렸을 때 score가 극적으로 변한다면 그 부분이 classification하는데 매우 중요한 부분이라고 판단하는 것이다.
- 그래서 빨간 부분일수록 classification할 때 중요한 부분임을 나타낸다.

#### 6. Saliency Maps

## Saliency Maps

How to tell which pixels matter for classification?




Compute gradient of (unnormalized) class score with respect to image pixels, take absolute value and max over RGB channels


Simonyan, Vedaldi, and Zisserman, "Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps", ICLR Workshop 2014.

Saliency map: 화면에서 눈에 띄는 영역, 다른 영역에 비해 픽셀값의 변화가 급격한 부분들을 모아서 mapping

- 즉 관심있는 물체를 관심이 없는 배경으로부터 분리시키는 것을 의미한다.
- image 각 pixel의 gradient를 map으로 시각화 한 것이다.
- actiavtion이 보고 있는 부분에서 backward를 하게 되면 값이 살아있게 된다.
- 따라서 Neural Network가 image의 어느 부분을 보고 있는지 알 수 있다.



### Saliency Maps: Segmentation without supervision




Use GrabCut on saliency map

Simonyan, Vedald, and Zisserman, "Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps", ICLR Workshop 2014.

- Saliency map를 이용하면 label를 주지 않는 un-supervised로 segmentation 작업을 진행할 수 있다.
- 하지만 정확도는 매우 떨어진다.

#### 7. Intermediate features via guided backprop

# Intermediate features via (guided) backprop



Pick a single intermediate neuron, e.g. one value in 128 x 13 x 13 conv5 feature map


Compute gradient of neuron value with respect to image pixels

Zeiler and Fergus, "Visualizing and Understanding Convolutional Networks", ECCV 2014
Springenhern at al. "Stripping for Simplicity. The All Commissional Net" ICLE Workshop 2015.

- 중간의 뉴런을 골라서 이미지의 어떤 patch가 영향을 크게 줬는지 확인한다.
- 1. Foward Pass
  - ReLU = max(0, x) 사용
- 2. Backward pass: backpropagation
  - 구해진 Gradient들 중 ReLU를 활성화했던 위치에만 Gradient 전달
  - 음수였던 영역은 전달하지 않는다.
- 3. Backward pass: deconvnet
  - 구해진 gradient가 음수이면 backward pass하지 않고 0 전달
  - 양수면 그대로 전달
- 4. Backward Pass: Guided Back Propagation
  - 기존의 Back Propagation + deconvnet
  - ReLu가 활성화 된 동시에 gradient가 양수인 값들만 전달
  - 이렇게 되면 activation이 높은 부분만 뒤로 갈수록 살아있게 되는데 이것은 Network가 classification에 이용했다는 걸로 해석할 수 있다.

#### 8. Visualizating CNN features: Grdaient Ascent

### Visualizing CNN features: Gradient Ascent




Images come out nicer if you only backprop positive gradients through each ReLU (guided backprop)

Figure copyright Jost Tobias Springenberg, Alexey Doscivitskiy, Thom Brox, Martin Riedmiller, 2015, reproduced with permission. (Guided) backprop:

Find the part of an image that a neuron responds to

Gradient ascent:

Generate a synthetic image that maximally activates a neuron




- 어떤 neuron(weight)가 주어졌을 때 그 neuron을 활성화시키는 gerneralized image는 어떤게 있을까?
- Gradient Ascent는 Loss가 최대가 되는 Parameter를 찾는 방법이다.
- 고정된 W에 대해 input image의 pixel value를 gradient ascent로 바꿔가면서 score가 최대가 되도록 한다.
- Overfit를 막기 위해 Regularization을 사용한다.


 $I^* = argmax_I f(I) + R(I)$ 

# Visualizing CNN features: Gradient Ascent

1. Initialize image to zeros



score for class c (before Softmax)




### Repeat:

- Forward image to compute current scores
- 3. Backprop to get gradient of neuron value with respect to image pixels
- 4. Make a small update to the image
- 1. pixel 초기화
- 2. score 계산을 위해 forward
- 3. 뉴런값과 기울기를 얻기 위해 backprop
- 4. gradient ascent 진행

# Visualizing CNN features: Gradient Ascent

 $\arg\max_{I} S_c(I) - \lambda ||I||_2^2$ 

Simple regularizer: Penalize L2 norm of generated image



Yosinski et al, "Understanding Neural Networks Through Deep Visualization", ICML DL Workshop 201-Figure copyright Jason Yosinski, Jeff Clune, Arih Nguyen, Thomas Fuchs, and Hod Lipson, 2014.


- L2 regularization을 사용시 형태를 알아보기 힘들다.
- 그래서 다른 regularizer를 사용하게 되었다.
- scroe를 최대화해야하기 때문에 regularization은 빼준다.


### Visualizing CNN features: Gradient Ascent

$$\arg\max_{I} S_c(I) - \lambda ||I||_2^2$$

Better regularizer: Penalize L2 norm of image; also during optimization periodically

- (1) Gaussian blur image
- (2) Clip pixels with small values to 0
- (3) Clip pixels with small gradients to 0





r latinings

Ground Beetle

Pelican

Indian Cobra

nski et al, "Understanding Neural Networks Through Deep Visualization", ICML DL Workshop 2014.

- 1. Gaussian blur 이미지
- 픽셀 중 작은 값을 가지는 것을 0으로
   픽셀 중 작은 gradient 가지는 것을 0으로

#### 9. Fooling Images / Adversarial Examples

### Fooling Images / Adversarial Examples


- (1) Start from an arbitrary image
- (2) Pick an arbitrary class
- (3) Modify the image to maximize the class
- (4) Repeat until network is fooled

- 1. 임의의 이미지에서 시작
- 2. 임의의 클래스를 선택
- 3. 클래스를 극대화하기 위해 이미지를 변경
- 4. network를 속일 때 까지 반복

#### 10. DeepDream: Amplify existing features

### DeepDream: Amplify existing features

Rather than synthesizing an image to maximize a specific neuron, instead try to **amplify** the neuron activations at some layer in the network



Choose an image and a layer in a CNN; repeat:

- 1. Forward: compute activations at chosen layer
- 2. Set gradient of chosen layer equal to its activation
- 3. Backward: Compute gradient on image
- Update image

Mordvintsey, Olah, and Tyka, 'Inceptionism: Going Deeper into Neural Networks', Google Research Root, Images are licensed under CC-8V

- 위에서는 특정 neuron을 maximaize하는 방향으로 시각화를 했다면, Deep Dream는 neuron activations를 증가시키는 방향의 차이가 있다
- 1. image와 CNN의 한 layer를 선택
- 2. layer까지 forward pass하고 activation 계산
- 3. layer의 gradient를 activation과 같게 설정
- 4. backward pass, update image

#### 11. Feature inversion

### Feature Inversion

Given a CNN feature vector for an image, find a new image that:

- Matches the given feature vector
- "looks natural" (image prior regularization)

$$\mathbf{x}^* = \operatorname*{argmin}_{\mathbf{x} \in \mathbb{R}^{H \times W \times C}} \ell(\Phi(\mathbf{x}), \overline{\Phi_0}) + \lambda \mathcal{R}(\mathbf{x}) \qquad \qquad \text{Features of new image}$$

$$\ell(\Phi(\mathbf{x}), \Phi_0) = \|\Phi(\mathbf{x}) - \Phi_0\|^2$$

$$\mathcal{R}_{V^\beta}(\mathbf{x}) = \sum_{i,j} \left( (x_{i,j+1} - x_{ij})^2 + (x_{i+1,j} - x_{ij})^2 \right)^{\frac{\beta}{2}} \qquad \qquad \text{Total Variation regularizer}$$
(encourages spatial smoothness)

Mahendran and Vedaldi, "Understanding Deep Image Representations by Inverting Them", CVPR 2015


Fei-Fei Li & Justin Johnson & Serena Yeung

Lecture 11 - 49 May 10, 2017

- 이미지가 네트워크를 통과시킨 후 만들어진 feature vector를 저장해준다.
- 이 feature vector를 이용해서 이미지를 재구성한다.
- 이로부터 이미지의 어떤 정보가 특정 벡터에서 포착되는지를 짐작할 수 있다.

### Feature Inversion

Reconstructing from different layers of VGG-16




• layer가 깊어질수록 변형이 심해지지만 이미지의 기초 형태는 유지하고 있다.


#### 12. Texture Synthesis

## Texture Synthesis: Nearest Neighbor






Generate pixels one at a time in scanline order; form neighborhood of already generated pixels and copy nearest neighbor from input



/ei and Levoy, "Fast Texture Synthesis using Tree-structured Vector Quantization", SIGGRAPH 2000 fros and Leung, "Texture Synthesis by Non-parametric Sampling", ICCV 1999


- 이미 생성된 픽셀들을 살핀 후 입력 패치에서 가장 가까운 픽셀을 계산해서 복사하여 불여넣는 방식이다.
- 하지만 naive한 방법으로 사용했을 때 복잡한 패턴을 키워보면 이상해지는 단점이 있었다.

#### 13. Gram Matrix




- 1. Input texture를 가지고 CNN에 넣는다
- 2. 어떤 layer에서 convolution된 feature C x H x W를 가져온다.

4. 모든 point에 대하여 만들고 average를 시키면 gram matrix가 생성된다.



- 1. 압력 이미지를 pretrain된 VGG network에 통과시켜 다양한 레이어에서 gram matrix를 계산한다.
- 2. 원본 이미지와 생성된 이미지의 gram matrix 간의 차이를 L2 norm을 이용하여 loss를 계산한다.
- 3. 계산된 loss를 이용하여 backpropagation을 진행
- 4. gradient ascent를 통해 이미지 픽셀들을 조금씩 업데이트
- 5. Gram matrix 계산  $\rightarrow$  loss 계산  $\rightarrow$  backprob을 반복하여 입력 텍스처와 유사한 텍스처를 만든다.


#### 14. Neural Style Transfer



- gram matrix를 이용한 텍서츠 합성을 두 이미지에 대해 적용하고 feature inversiong을 조합한다.
- 이것이 style transfer이다.

### Fast Style Transfer

- (1) Train a feedforward network for each style
- (2) Use pretrained CNN to compute same losses as before
- (3) After training, stylize images using a single forward pass



Fei-Fei Li & Justin Johnson & Serena Yeung

Lecture 11 - 78 May 10, 2017

- Fast Style Transfer는 style이미지를 고정시킨 후 content image만을 입력 받아 결과를 출력할 수 있는 단일 네트워크를 학습시키는 방법이다.
- semantics segmentation과 매우 유사하다.